

ELBO (证据下界) 综述

聂宇航

信息科学与工程学部, 中国海洋大学, 山东青岛

nieyuhang@stu.ouc.edu.cn

<http://www.ouc.edu.cn>

摘要: 证据下界 (Evidence Lower Bound, *ELBO*) 是变分推断 (Variational Inference) [1] 的理论基石, 通过优化可处理的变分分布逼近复杂后验分布, 解决概率模型中隐变量推断的难解性问题。本文系统综述 *ELBO* 的数学本质、推导方法、优化策略与应用前沿。

Keywords: 证据下界 (*ELBO*) ; 变分推断; KL 散度; 重参数化技巧; 隐变量模型; 变分自编码器 (VAE) ; 贝叶斯神经网络 (BNN) ; 后验近似; 蒙特卡洛估计; 重要性加权自编码器 (IWAE) ;

1. 引言

在当代机器学习与统计建模中, 复杂概率模型的构建已成为刻画高维不确定性数据的重要手段。然而, 在这类模型中往往涉及隐变量 (latent variables) [2], 如图模型中的隐状态、生成模型中的潜在表示等。这些隐变量使得后验分布 $p(z|x)$ 难以精确计算, 尤其在缺乏解析解或需要高维积分的情形下, 后验推断成为学习中的主要瓶颈。

为了解决这一难题, 研究者提出了多种近似推断方法。其中, 变分推断 (Variational Inference, VI) 作为一种高效的优化方法, 近年来受到广泛关注。它将后验推断问题转化为变分分布 $q(z)$ 与真实后验 $p(z|x)$ 之间的距离最小化问题。具体而言, VI 通过引入可调变分族 Q , 用优化替代采样, 避免了马尔可夫链蒙特卡洛 (MCMC) 方法常见的收敛性难题与采样效率低下的问题。在变分推断中, 证据下界 (Evidence Lower Bound, *ELBO*) 作为核心目标函数, 承载着连接观测数据似然 $p(x)$ 、模型联合分布 $p(x, z)$ 、以及变分分布 $q(z)$ 的重要作用。*ELBO* 的最大化不仅是推断质量的度量标准, 更是近似后验与生成模型的学习信号。最大化 *ELBO* 等价于最小化 $KL(q(z)||p(z|x))$, 从而实现模型学习与推断质量的统一。

随着深度学习的兴起, *ELBO* 被广泛应用于变分自编码器 (VAE)、贝叶斯神经网络、主题模型、图神经网络 [3] 等领域, 成为现代生成建模与不确定性量化的理论基石。此外, 围绕 *ELBO* 的优化方法与理论改进也不断发展, 如重参

数化技巧、重要性加权下界 (IWAE)、 χ 散度下界、半摊销推断 (semi-amortized inference) [4] 等，极大地扩展了其适用范围和表达能力。

本文旨在系统梳理 *ELBO* 的理论基础、数学推导、物理意义与优化技术，并总结其在深度学习与贝叶斯建模中的典型应用与研究进展。通过对 *ELBO* 的全面综述，我们希望为读者提供一个统一的理解框架，帮助其把握这一核心工具的本质与发展趋势。

2. *ELBO* 的数学基础与推导 [5-7]

2.1. 问题定义与建模背景

我们最主要的目标是对一个含隐变量的分布模型进行参数估计。假设可观察变量是 x ，隐变量是 z ，待估计的参数是 θ 。我们一般会使用最大似然估计 (MLE) 来进行估计，但由于有隐变量，我们会使用 EM 算法。EM 算法本质上还是 MLE，只不过会在每次 MLE 之前先估计并固定住隐变量。

现在我们要对观察变量做最大似然估计，即最大化以下函数：

$$L(\theta) = \int_{x \sim p(x)} \log p_{\theta}(x)$$

但由于模型中有隐变量，所以我们必须把隐变量确定下来，这样就可以正常地做 MLE 了。至于如何根据观察把隐变量确定下来，我们的思路也很容易想到，即使用贝叶斯推断：

$$p(z|x) = p(z) \frac{p(x|z)}{p(x)}$$

得到隐变量的后验分布 $p(z|x)$ 之后，我们并不打算去估计出某个确定的值，因为我们认为这样会损失更多信息。我们的打算是把整个分布都利用起来，即：

$$L(\theta) = E_x[L_x(\theta)] = E_x[\log p_{\theta}(x)]$$

其中：

$$\begin{aligned} L_x(\theta) &= \log p_{\theta}(x) \\ &= \log(E_z[p_{\theta}(x, z)]) \\ &= \log(E_z[p_{\theta}(z|x)p_{\theta}(x)]) \\ &= \log(E_z[p_{\theta}(z|x) \frac{p_{\theta}(x, z)}{p_{\theta}(z|x)}]) \end{aligned}$$

在上式的第二个等号，我使用乘法公式（贝叶斯公式）分解出 z 的后验分布；而在第三个等号，我再次使用乘法公式把 $p_\theta(x)$ 分解为 $\frac{p_\theta(x,z)}{p_\theta(z|x)}$ 来计算，因为 $p_\theta(z|x)$ 没法儿算。看上去，这就好像在 $p_\theta(x,z)$ 上做了一个同时乘和除 $p_\theta(z|x)$ 的数学技巧，但它实际上是有动机的。

但 $p_\theta(z|x)$ 是难以计算的。例如，在 VAE 中，这儿的 θ 代表的是解码器的参数。根据解码器输出高斯分布的假设，显然我们可以显式地计算出 $p_\theta(x|z)$ ；而我们又有解码器输入、即隐变量先验为标准高斯分布的假设，所以也可以显式地写出 $p_\theta(z)$ （就是标准高斯），然而我们无法从解码器中得到 $p_\theta(z|x)$ 。

在数学上看 $p(z|x) = \frac{p(x,z)}{p(x)}$ ，其中 $p(x) = \int p(x,z) = \int p(x|z)p(z)$ 通常是一个高阶积分，难以求解。

因此为了另辟蹊径，我们使用变分推断来近似计算 $p_\theta(z|x)$ 。

2.2. 从 KL 散度视角导出 ELBO [8-10]

对于我们的目标 $p_\theta(z|x)$ ，我们要找一个最好的 $q_\phi(z|x)$ 来近似它。怎么样的近似才好呢，标准就是最小化 KL 散度，即 $KL(q_\phi(z|x)||p_\theta(z|x))$

那为什么是 KL 散度呢 $KL(q(z)||p(z)) = \int q(z)\log\frac{q(z)}{p(z)}dz$ ，而不是我们可以轻松的想到 $\int (q(z)-p(z))^2dz$ 或者 $\int |q(z)-p(z)|dz$ 呢？

因为 KL 散度代表：如果我们用 $q(z)$ 来编码数据，而数据实际上来自 $p(z)$ ，我们每单位多用了多少“信息”。这直接连到压缩理论、通信理论，和“最优表示”的理论目标一致。并且 KL 散度对常见分布（如高斯）有解析解，以及它是光滑的、可导的，能反向传播优化。如果把 $q_\phi(z|x)$ 看成自变量函数，那么这个散度就是关于它的一个泛函，于是我们现在正是在求一个泛函极值问题。现在来求这个泛函极值问题：

$$KL(q_\phi(z|x)||p_\theta(z|x)) = \int_z q_\phi(z|x)\log\frac{q_\phi(z|x)}{p_\theta(z|x)}dz$$

问题是我们的目标就是 $p_\theta(z|x)$ ，积分里还有它、肯定没法求。得把它拆开，还是用乘法公式，就得到：

$$\int_z q_\phi(z|x)\log\frac{q_\phi(z|x)p_\theta(x)}{p_\theta(x,z)}dz$$

再化个简，把跟积分变量 z 无关的项 $p_\theta(x)$ 剥离出来：

$$\begin{aligned}
 KL(q_\phi(z|x)||p_\theta(z|x)) &= \int_z q_\phi(z|x) \log \frac{q_\phi(z|x)p_\theta(x)}{p_\theta(x,z)} dz \\
 &= \int_z q_\phi(z|x) \log \frac{q_\phi(z|x)}{p_\theta(x,z)} dz + \int_z q_\phi(z|x) \log p_\theta(x) dz \\
 &= \int_z q_\phi(z|x) \log \frac{q_\phi(z|x)}{p_\theta(x,z)} dz + \log p_\theta(x) \int_z q_\phi(z|x) dz \\
 &= \int_z q_\phi(z|x) \log \frac{q_\phi(z|x)}{p_\theta(x,z)} dz + \log p_\theta(x)
 \end{aligned}$$

改写为以似然为中心：

$$L_x(\theta) = \log p_\theta(x) = \int_z q_\phi(z|x) \log \frac{p_\theta(x,z)}{q_\phi(z|x)} dz + KL(q_\phi(z|x)||p_\theta(z|x))$$

左边这项 $\int_z q_\phi(z|x) \log \frac{p_\theta(x,z)}{q_\phi(z|x)} dz = E_{q_\phi(z|x)}[\log \frac{p_\theta(x,z)}{q_\phi(z|x)}]$ 就是 $ELBO$ 。让我们继续看看它的内涵：

$$\begin{aligned}
 ELBO &= \int_z q_\phi(z|x) \log \frac{p_\theta(x,z)}{q_\phi(z|x)} dz \\
 &= \int_z q_\phi(z|x) \log \frac{p_\theta(x|z)p_\theta(z)}{q_\phi(z|x)} dz \\
 &= E_{q_\phi(z|x)}[\log p_\theta(x|z)] + E_{q_\phi(z|x)}[\log \frac{p_\theta(z)}{q_\phi(z|x)}] \\
 &= E_{q_\phi(z|x)}[\log p_\theta(x|z)] - KL(q_\phi(z|x)||p_\theta(z))
 \end{aligned}$$

现在， $L_x(\theta)$ 中除了 $KL(q_\phi(z|x)||p_\theta(z|x))$ 项，其他地方都不再包含 $p_\theta(z|x)$ ，取而代之的是编码器 $q_\phi(z|x)$ 。所以，我们干脆丢掉 $KL(q_\phi(z|x)||p_\theta(z|x))$ ，只最大化 $ELBO$ ，从而不再有任何计算障碍。事实上，由于 $KL(q_\phi(z|x)||p_\theta(z|x)) \geq 0$ （等号成立当且仅当 $p_\theta(z|x) = q_\phi(z|x)$ ），所以我们有：

$$L_x(\theta) = \log p_\theta(x) \geq ELBO$$

所以，我们实际上是在最大化似然的下界。实际上，因为 $p_\theta(x)$ 又叫证据，所以 $ELBO$ 叫做 $ELBO$ （证据下界）。然而，直接丢弃 $KL(q_\phi(z|x)||p_\theta(z|x))$ 是合理的吗？是合理的，而合理性本质上是由 EM 算法保证的。

2.3. 从 Jensen 不等式推导 ELBO ^[11-12]

ELBO 也可以通过 Jensen 不等式直接从 $\log p_\theta(x)$ 的定义导出：

$$\begin{aligned}
 L_x(\theta) &= \log p_\theta(x) = \log \int_z p_\theta(x, z) dz \\
 &= \log \int_z \frac{q_\phi(z|x)}{q_\phi(z|x)} p_\theta(x, z) dz \quad (p_\theta(x, z) = p_\theta(x|z)p(z)) \\
 &= \log \int_z q_\phi(z|x) \frac{p_\theta(x|z)p(z)}{q_\phi(z|x)} dz \quad (\text{对数是凹函数, 使用 Jensen 不等式}) \\
 &\geq \int_z q_\phi(z|x) \log \frac{p_\theta(x|z)p(z)}{q_\phi(z|x)} dz \\
 &= E_{x \sim q_\phi(z|x)} \left[\frac{\log p_\theta(x, z)}{q_\phi(z|x)} \right] = ELBO = \mathcal{L} \\
 &= \int_z q_\phi(z|x) \log p_\theta(x|z) dz + \int_z q_\phi(z|x) \log \frac{p(z)}{q_\phi(z|x)} dz \\
 &= \int_z q_\phi(z|x) \log p_\theta(x|z) dz - KL[q_\phi(z|x) || p(z)] \\
 &= E_{x \sim q_\phi(z|x)} [\log p_\theta(x|z)] - KL[q_\phi(z|x) || p(z)]
 \end{aligned}$$

综上所述，这就是 ELBO 的数学定义：

$$ELBO(\theta, \sigma) = E_{x \sim q_\phi(z|x)} [\log p_\theta(x|z)] - KL[q_\phi(z|x) || p(z)]$$

也可以这样表示：

$$\begin{aligned}
 \mathcal{L}(\theta, \sigma) &= E_{x \sim q_\phi(z|x)} [\log p_\theta(x|z)] - KL[q_\phi(z|x) || p(z)] \\
 \mathcal{L}(q) &= E_q(z) [\log p(x|z)] - E_q(z) [\log q(z)] \\
 \mathcal{L}(q) &= E_q(z) [\log p(x|z)] - KL(q(z) || p(z))
 \end{aligned}$$

2.4. ELBO 的分解形式与直观意义 ^[13]

$$ELBO(\theta, \sigma) = E_{x \sim q_\phi(z|x)} [\log p_\theta(x|z)] - KL[q_\phi(z|x) || p(z)]$$

这个形式清晰地展现了 ELBO 的两个组成部分：

重构项 (Reconstruction Term)： $E_{x \sim q_\phi(z|x)} [\log p_\theta(x|z)]$ ，衡量潜变量对数据的重构能力。

正则项 (Regularization Term)： $KL[q_\phi(z|x) || p(z)]$ ，约束变分分布不要偏离先验过远。

对于重构项，我们希望它越大越好，如下为推导：

$$Sample\{x^1, x^2, \dots, x^m\} \text{ from } P_{data}(x)$$

$$\begin{aligned}\theta^* &= \arg \max_{\theta} \prod_{i=1}^m P_{\theta}(x^i) = \arg \max_{\theta} \log \prod_{i=1}^m P_{\theta}(x^i) \\ &= \arg \max_{\theta} \sum_{i=1}^m \log P_{\theta}(x^i) \approx \arg \max_{\theta} E_{x \sim P_{data}} [\log P_{\theta}(x)] \\ &= \arg \max_{\theta} \int_x P_{data}(x) \log P_{\theta}(x) dx - \int_x P_{data}(x) \log P_{data}(x) dx \\ &= \arg \max_{\theta} \int_x P_{data}(x) \log \frac{P_{\theta}(x)}{P_{data}(x)} dx \\ &= \arg \min_{\theta} KL(P_{data} || P_{\theta})\end{aligned}$$

即最大似然估计等价于最小化数据分布和模型分布之间的 KL 散度。

最大化模型生成数据的概率（似然）是目标，重构项是生成模型 $p_{\theta}(x|z)$ 的关键部分；所以重构项越大，说明模型越会“模仿数据”，最终越接近真实分布。这就是它与最大似然推导中 KL 散度之间的桥梁关系。

3. ELBO 的物理意义与性质

3.1. 下界属性与推理目标

在变分推断框架中，ELBO 作为对对数边缘似然 $\log p_{\theta}(x)$ 的下界，有着清晰的优化目标与物理含义。根据前一章推导：

$$\log p_{\theta}(x) = ELBO + KL[q_{\phi}(z|x) || p_{\theta}(z)]$$

由于 KL 散度非负（即 $KL[q_{\phi}(z|x) || p_{\theta}(z)] \geq 0$ ，我们有：

$$\log p_{\theta}(x) \geq ELBO$$

这说明：最大化 ELBO 即间接提升了模型的边缘似然 $p(x)$ ，从而提高模型生成数据的能力。因此，ELBO 的优化可以视为一个可计算的替代目标，用于逼近原本不可解的最大似然估计问题。

3.2. 后验近似质量的衡量指标

$ELBO$ 不仅是一个优化目标，也可以用来衡量变分分布与真实后验之间的接近程度。由下式：

$$\log p_{\theta}(x) - ELBO = KL[q_{\phi}(z|x)||p_{\theta}(z)]$$

我们知道，当 $q_{\phi}(z|x) = p_{\theta}(z)$ 时， $ELBO$ 与 $\log p_{\theta}(x)$ 相等，此时变分推断得到最优解。因此， $ELBO$ 越接近 $\log p_{\theta}(x)$ ，说明变分分布对后验的近似质量越高。但由于 $\log p_{\theta}(x)$ 通常无法直接计算，这种差距本身在实际中无法精确评估，因此 $ELBO$ 也被视为一种代理目标 (surrogate objective)：在不直接访问真实后验的前提下，提供一种逐步改进近似分布的方式。

3.3. 重构-正则化的权衡关系

3.3.1. 引入超参数 β [14–15]

我们可以引入通过引入超参数 β 显式控制 $ELBO$ 中重构项与正则项的权重，系统研究两者的权衡关系，修改标准 $ELBO$ ，引入系数：

$$L(\theta, \sigma; x, \beta) = E_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] - \beta KL(q_{\phi}(z|x)||p(z))$$

β 的作用：

增大 β 加强 KL 项的惩罚，迫使隐变量 z 更严格匹配先验 $p(z)$ (通常为标准高斯)。

减小 β 放宽正则化约束，优先优化重构精度。

强正则化 ($\beta > 1$):

KL 项主导优化，迫使每个隐变量维度 z_i 独立且高斯分布。

效果：隐空间维度与数据中的基本视觉概念（如物体形状、颜色、位置）对齐，实现解耦表示。

弱正则化 ($\beta < 1$):

重构项主导优化，允许隐变量偏离先验分布。

效果：模型更关注数据细节，生成图像更清晰，但隐变量可能耦合多个特征（可解释性下降）。

$\beta \rightarrow 0$ 退化为自编码器（无正则化，隐空间无结构）。

$\beta \rightarrow \infty$ 隐变量完全匹配先验（生成能力崩溃）。

3.3.2. 不固定 β ，逐渐增加 KL 的目标值 [16]

对于原本的 $\beta - ELBO$ 将其改写为带约束的优化问题：

$$\max_{\theta, \sigma} E_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] \quad s.t. \quad KL(q_{\phi}(z|x)||p(z)) \leq C$$

其中 C 为 KL 散度的目标容量 (Capacity)，随训练逐步增加 (如线性增长： $C_t = C_{min} + \frac{t}{T}(C_{max} - C_{min})$)。

通过拉格朗日乘子法，将约束优化转化为无约束问题：

$$L(\theta, \sigma; x, \beta) = E_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] - \lambda(KL(q_{\phi}(z|x)||p(z)) - C)$$

λ 为动态调整的拉格朗日乘子，通过梯度下降更新：

$$\lambda \leftarrow \lambda + \eta(KL(q_{\phi}(z|x)||p(z)) - C)$$

其中 η 为学习率。

与 $\beta - ELBO$ 的关系

当 λ 收敛时，等价于固定 $\beta = \lambda$ ，但 KL Capacity 的 λ 是自适应调整的，且 C 逐步增加，避免了静态 β 的局限性。

Capacity 调度策略：

线性增长： $C_t = C_{min} + \frac{t}{T}(C_{max} - C_{min})$

余弦退火： $C_t = C_{min} + \frac{t}{T}(C_{max} - C_{min})(1 - \cos(\frac{t}{T}))$ 目标值选择：

C_{min} ：初始容量 (如 0)，允许模型早期自由学习。

C_{max} ：最终容量 (如 20~50)，控制解耦强度。

训练初期， KL 容量 C 较小，模型优先优化重构项，学习有意义的隐变量表示。训练后期，逐步增大 C ，迫使隐变量分布逐渐逼近先验，实现解耦。在训练期间会进行自适应平衡：拉格朗日乘子 λ 自动调节 KL 项的权重，避免人工调参，解耦与生成质量更优。

3.4. 多任务视角与平衡策略 [17]

通过显式解耦总相关性 (Total Correlation, TC) 来增强隐变量的独立性。结合 Capacity Constraint (动态调整 KL 约束)，可以更灵活地平衡解耦与生成质量。

总相关性 (TC) 的定义:

TC 衡量隐变量维度之间的依赖性:

$$TC(q_\phi(z)) = KL(q_\phi(z) || \prod_{j=1}^d q_\phi(z_j))$$

$q_\phi(z)$ 是隐变量的聚合后验

$\prod_{j=1}^d q_\phi(z_j)$ 是假设各维度独立时的联合分布

$TC = 0$ 表示所有维度完全独立

显式优化 TC 项:

$$L_{TC} = E_{q_\phi(z|x)}[\log p_\theta(x|z)] - \alpha KL(q_\phi(z|x) || p(z)) - \beta TC(q_\phi(z))$$

α 控制先验匹配强度 (默认 $\alpha=1$)。

β 控制解耦强度 (通常 $\beta>1$)。

直接计算 TC 需要估计 $q_\phi(z)$ ，但其解析形式未知。TC-VAE 采用两种估计策略:

(1) 密度比估计:

利用判别器 $D(z)$ 区分样本来源:

$$TC(q_\phi(z)) \approx E_{q_\phi(z)}[\log \frac{D(z)}{1-D(z)}]$$

正样本: 从 $q_\phi(z)$ 采样 (即 $z \sim q_\phi(z), x \sim p_{data}(x)$)。

负样本: 从 $\prod_{j=1}^d q_\phi(z_j)$ 采样 (各维度独立重排)。

(2) Minibatch 加权采样:

通过 minibatch 近似 $q_\phi(z)$:

$$TC \approx E_{q_\phi(z)}[\log q_\phi(z)] - \sum_{j=1}^d E_{q_\phi(z)}[\log q_\phi(z_j)]$$

计算复杂度高，但对小规模数据可行。

动态约束的数学形式

将 TC 和 KL 项分别施加容量约束:

$$L_{TC+Capacity} = E_{q_\phi(z|x)}[\log q_\phi(x|z)] - \lambda_1 (KL(q_\phi(z|x) || p(z)) - C_{KL}) - \lambda_2 (TC(q_\phi(z)) - C_{TC})$$

C_{KL} 和 C_{TC} 是逐步增加的容量目标。

λ_1, λ_2 为拉格朗日乘子，通过梯度上升更新：

$$\lambda_i \leftarrow \lambda_i + \eta(\text{Constraint}_i - C_i)$$

容量调度策略：

KL 容量 (C_{KL})：从 0 线性增长到目标值（如 20）。

TC 容量 (C_{TC})：从 0 增长到更低的值（如 5），因为 TC 的解耦需求通常弱于全局 KL 。

其可以通过 TC 项直接优化隐变量独立性。并且可以动态平衡容量约束，实现训练过程的自动调参。

4. $ELBO$ 的优化方法

变分推断的核心任务是最大化 $ELBO$ ，从而近似计算后验分布。由于 $ELBO$ 涉及期望运算与 KL 散度，其优化在理论与工程实践中均面临挑战。本章将综述常见的 $ELBO$ 优化方法，涵盖解析推导、数值估计与现代深度学习中的变分推断技术。

4.1. 坐标上升法：Mean-Field 变分推断 [18–20]

Mean-Field 变分推断 (Mean-Field Variational Inference, MFVI) 是变分推断中最经典的方法之一，其核心思想是通过坐标上升法 (Coordinate Ascent) 迭代优化 $ELBO$ 。假设隐变量 $\mathbf{z} = (z_1, z_2, \dots, z_K)$ 的各维度完全独立，变分分布分解为：

$$q(\mathbf{z}) = \prod_{k=1}^K q_k(z_k)$$

每个 $q_k(z_k)$ 是边缘分布（如高斯、伯努利等）。

该假设简化了计算，但牺牲了隐变量间的相关性建模能力。

在 Mean-Field 假设下， $ELBO$ 可写为：

$$\begin{aligned} \mathcal{L}(q) &= E_{q(\mathbf{z})}[\log p(\mathbf{x}, \mathbf{z})] - E_{q(\mathbf{z})}[\log q(\mathbf{z})] \\ &= E_{q(\mathbf{z})}[\log p(\mathbf{x}, \mathbf{z})] - \sum_{k=1}^K E_{q_k(z_k)}[\log q_k(z_k)] \end{aligned}$$

固定其他维度，优化单维度 q_k 对每个 $q_k(z_k)$ ，固定其他 $q_{-k}(z_{-k}) = \prod_{j \neq k} q_j(z_j)$ ， $ELBO$ 中仅与 q_k 相关的项为

$$\begin{aligned}\mathcal{L}(q_k) &= E_{q_k(z_k)} E_{q_{-k}(\mathbf{z}_{-k})} [\log p(\mathbf{x}, \mathbf{z})] - E_{q_k(z_k)} [\log q_k(z_k)] + \text{const} \\ &= E_{q_k(z_k)} E_{q_{-k}(\mathbf{z}_{-k})} [\log p(\mathbf{x}, \mathbf{z})] - \log \tilde{p}_k(z_k) \\ &= -KL(q_k(z_k) || \tilde{p}_k(z_k))\end{aligned}$$

最大化 $ELBO$ 等价于最小化 KL 散度，因此最优解为：

$$q_k^*(z_k) \propto \exp(E_{q_{-k}(\mathbf{z}_{-k})} [\log p(\mathbf{x}, \mathbf{z})])$$

对每个维度 k ，按以下步骤更新：

计算期望：

$$\log q_k(z_k) \leftarrow E_{q_{-k}(\mathbf{z}_{-k})} [\log p(\mathbf{x}, \mathbf{z})] + \text{const}$$

归一化：

$$\log q_k(z_k) = \frac{\exp(E_{q_{-k}(\mathbf{z}_{-k})} [\log p(\mathbf{x}, \mathbf{z})])}{\int \exp(E_{q_{-k}(\mathbf{z}_{-k})} [\log p(\mathbf{x}, \mathbf{z})]) dz_k}$$

Mean-Field 变分推断中的坐标上升法通过迭代优化单变量边缘分布最大化 $ELBO$ ，这种方法适用于具有共轭先验的模型，如变分贝叶斯 LDA、GMM、贝叶斯回归等，更新过程高效且收敛稳定。

4.2. 随机梯度变分推断 (SGVI): *Black-Box* 方法 ^[21–22]

针对复杂模型、非共轭结构以及神经网络等不具备解析解的情况，采用黑盒变分推断 (Black-Box Variational Inference)，即通过采样与梯度估计进行优化。

梯度估计公式： $ELBO$ 关于变分参数 ϕ 的梯度可写为：

$$\nabla_{\phi} \mathcal{L}(\phi) = \nabla_{\phi} E_{q_{\phi}(z)} [\log p(x, z) - \log q_{\phi}(z)]$$

由于期望不可解析，可通过蒙特卡洛采样估计：

$$\nabla_{\phi} \mathcal{L} \approx \frac{1}{K} \sum_{k=1}^K \nabla_{\phi} \log q_{\phi}(z) [\log p(x, z) - \log q_{\phi}(z)]$$

这种方法通用性强，但方差较高，常需方差控制技术如 control variates 辅助。

4.3. 重参数化技巧 (*Reparameterization Trick*) [23]

引入了重参数化技巧，可以极大降低梯度估计的方差，使得 *ELBO* 在神经网络中可直接通过反向传播进行优化。

将 $z \sim q_\phi(z, x)$ 转换为一个确定函数：

$$z = g_\phi(\epsilon), \epsilon \sim p(\epsilon)$$

例如对高斯分布：

$$z = \mu(x) + \sigma(x)\epsilon, \epsilon \sim \mathcal{N}(0, 1)$$

此时 *ELBO* 的梯度变为：

$$\nabla_\phi \mathcal{L} \approx \frac{1}{K} \sum_{k=1}^K \nabla_\phi \log p(x, g_\phi(\epsilon_k)) - \log q_\phi(g_\phi(\epsilon_k)|x)$$

该技巧目前被广泛用于 VAE、Bayesian Neural Network 等深度模型中。

4.4. 自然梯度变分推断 (*Natural Gradient VI*) [24–25]

标准梯度在高维概率分布参数空间中更新效率低下。自然梯度 (Natural Gradient) 在信息几何上考虑变分分布之间的真实“距离”，提高了收敛速度和稳定性。

核心思想：

使用变分参数的 Fisher 信息矩阵 $F(\phi)$ ，更新方向变为：

$$\tilde{\nabla}_\phi \mathcal{L} = F(\phi)^{-1} \nabla_\phi \mathcal{L}$$

在指数族分布中，自然梯度往往有简洁的闭式形式；在深度学习中，也有 K-FAC 等近似方法用于高效计算。

5. *ELBO* 的典型应用场景

ELBO (Evidence Lower Bound) 不仅是变分推断的核心目标函数，更是多个现代概率模型和生成模型中的理论基石。由于其能有效逼近后验分布与边缘似然，*ELBO* 被广泛用于各种贝叶斯模型、深度生成模型、聚类模型等领域。以下将列举 *ELBO* 的典型应用场景，并简要介绍其在具体模型中的作用。

5.1. 变分自编码器 (*Variational Autoencoders, VAE*) [26–28]

VAE 是 *ELBO* 在深度学习中最具代表性的应用。其基本思想是引入隐变量 z 来建模数据 x 的生成过程，通过最大化 *ELBO* 学习生成模型的参数。

5.1.1. VAE 的结构组成

编码器 (Encoder) :

将输入 x 映射为潜在变量 z 的分布:

$$q_{\phi}(z|x)$$

常假设这个分布是正态分布 $\mathcal{N}(\mu, \sigma^2)$ 由神经网络输出 $\mu(x), \sigma(x)$ 。

什么是映射呢? 我们不再像传统自编码器那样把输入压缩成一个固定的向量 z , 而是将 x 映射成一个概率分布 (比如正态分布), 然后从这个分布中采样得到 z 。

传统 AutoEncoder 的做法:

给定一个图片 x , 编码器输出一个向量 $z = f(x)$ 。这个 z 是固定的——每次输入 x , 输出都是一样的 z 。

VAE 的做法:

给定一个图片 x , 编码器输出的是两个向量: $\mu(x), \sigma(x)$, 它们定义了一个分布 $q_{\phi}(z|x) = \mathcal{N}(z; \mu, \sigma^2)$ 我们从这个分布中随机采样一个 z , 再输入给解码器重建。这个“随机性”可以让模型更有泛化能力, 也让它能学习生成模型。

编码器不是输出一个确定的潜在向量 z , 而是输出一个高斯分布 (用均值和标准差描述), 表示“这张图片在潜在空间中可能落在什么位置”, 从而可以采样多个 z , 用于生成或重建。

解码器 (Decoder) :

根据潜在变量 z 重建原始输入:

$$p_{\theta}(x|z)$$

这是一个从潜在空间回到数据空间的映射, 也是一个神经网络。

解码器是一个神经网络, 学习的是 $p_{\theta}(x|z)$ 也就是在给定潜在变量 z 的条件下, 输入数据 x 的概率。就是希望这个解码器能够生成尽量接近原始输入 x 的输出。

传统 AutoEncoder 的做法:

将压缩后的向量还原为原始数据

VAE 的做法:

将从分布中采样的 z 还原为原始数据, 并保证可以“生成”新样本。它还可以通过在两个 z_1, z_2 之间线性插值, 然后解码, 得到连续变化的图像 (比如从“3”慢慢变成“8”), 并在潜在空间中轻微扰动 z , 可得到风格变化图像。

所以 VAE 可以输入一个样本, 输出一个和样本相似的东西。

5.1.2. 为什么叫“变分”自编码器

VAE 使用了变分推断思想，通过优化 $ELBO$ 目标函数，来近似最大化数据的对数似然 $\log p(x)$

什么是 $p(x)$ ，我们为什么需要这个 $p(x)$ ？

$p(x)$ 是模型生成某个具体样本 x 的“概率”。它告诉我们，模型认为这个样本有多“合理”或“典型”。

为什么要关心 $p(x)$ ？

我们训练生成模型的目标，实际上是让模型能够给训练数据（和相似数据）更高的概率，即模型能更好地理解数据的分布。这意味着，最大化所有训练样本的 $p(x)$ ，使模型“学会”训练集的分布。模型能用它学到的概率规则，生成类似训练数据的样本。 $p(x)$ 通常很小，怎么办？

数据空间（比如图像空间）极其庞大且稀疏，一个具体的样本 x 的概率往往非常小，甚至趋近于 0。但这没关系，因为我们比较的是不同样本的概率大小关系，而不是概率绝对值。所以通常用对数概率来表示，更易于比较和优化。

在网络中 $p(x)$ 不只是一个评价网络好坏的标准，我们还使用它训练我们的网络，但训练时不直接用 $p(x)$ 计算梯度，但它太难算了，所以我们训练用的是 $ELBO$ 。 $ELBO$ 是一个可计算、可导的目标函数，方便我们用梯度下降优化。在 VAE 训练里，我们通过计算 $ELBO$ 的梯度来更新编码器和解码器的参数。

5.2. 贝叶斯神经网络 (Bayesian Neural Networks, BNN) [29–30]

在普通的神经网络中，训练的目标是找到一组最优参数 θ （例如权重、偏置），使得网络在训练集上表现最好。但是它没有考虑一个问题，如果训练数据不够充分、带有噪声，为什么我们要那么“确信”这组参数是最优的？

所以贝叶斯神经网络 BNN 不是寻找“最优权重”，而是为每个权重分配一个概率分布，AVE 是将输入概率化的话，那么 BNN 就是将权重概率化。训练时，我们的思想和 VAE 一样，使用变分推断。

假设我们有训练数据集：

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^N$$

我们关心的是，给定数据 D ，推断参数 θ 的后验分布：

$$p(\theta|D) = \frac{p(D|\theta)}{p(D)}$$

前面也说了这个后验通常非常难直接计算（高维积分、没有闭式解），所以我们采取变分推断方法进行近似。
我们构造一个可学习的近似分布 $q_\phi(\theta)$ ，其目标是：

$$\begin{aligned}\log p(D) &= \log \int p(D | w)p(w) dw \\ &= \log \int q(w) \frac{p(D | w)p(w)}{q(w)} dw \\ &\geq \int q(w) \log \frac{p(D | w)p(w)}{q(w)} dw \\ &= \mathbb{E}_{q(w)}[\log p(D | w)] - \text{KL}(q(w)||p(w)) \\ &= \mathcal{L}(q)\end{aligned}$$

$p(D|w)$: 似然项（神经网络的预测概率）
 $p(w)$: 先验分布（常为标准正态）
 $q(w)$: 近似后验分布（可参数化为高斯分布）
 $\text{KL}(q(w)||p(w))$ 正则项，鼓励 $q(w)$ 不偏离先验

这意味着我们希望 $q_\phi(\theta)$ 逼近真实后验。由于 $p(\theta|D)$ 包含不可计算的 $p(D)$ ，这个目标等价于最大化 $ELBO$ ，也就是 BNN 的训练目标：

$$\log p(D) \geq E_{q_\phi(\theta)}[\log p(D|\theta)] - \text{KL}(q_\phi(\theta)||p(\theta))$$

在预测的时候我们就不要算复杂的积分了，只需要从 $q_\phi(\theta)$ 中采样多组 θ ，对每组 θ 计算 $p(y^*, x^*, \theta)$ 最终取平均，获得预测分布。
预测时综合所有可能的模型（权重），自然具备“模型集成”和“不确定性量化”的能力。

5.3. 潜在主题模型（如 *Latent Dirichlet Allocation, LDA*）^[31]

LDA 是文本分析中的经典模型，用于从文档中挖掘潜在主题。其模型包含文档-主题分布和主题-词分布等多个隐变量，直接推断后验分布不可行。使用我们必须使用变分方法了，可以使用 Mean-field 结构近似各隐变量后验，然后最大化 $ELBO$ 以优化主题分布与词分布。

变分 LDA 是早期变分推断的重要成果，也是自然语言处理领域中 $ELBO$ 的成功应用实例。

5.4. 贝叶斯高斯混合模型 (*Bayesian GMM*) [32]

高斯混合模型是无监督学习中的经典聚类模型，引入贝叶斯推断后，对每个样本的类别分布和模型参数引入不确定性。

ELBO 表达式：

$$\begin{aligned}\log p(X) &= \log \int p(X, Z, \pi, \mu, \Lambda) dZ d\pi d\mu d\Lambda \\ &\geq \mathbb{E}_{q(Z, \pi, \mu, \Lambda)} \left[\log \frac{p(X, Z, \pi, \mu, \Lambda)}{q(Z, \pi, \mu, \Lambda)} \right] \\ &= \mathcal{L}(q)\end{aligned}$$

其中， z 表示隐类别标签， π, μ, Λ 为混合参数。*ELBO* 优化过程可由变分 EM 或随机推断方法实现，使模型在聚类任务中更具鲁棒性与泛化能力。

5.5. 强化学习中的贝叶斯策略优化 [33–34]

在强化学习中，策略的不确定性建模成为提升探索效率的重要手段。基于 *ELBO* 的贝叶斯策略优化方法，如 Variational Policy Search，使用变分方法估计策略后验。

ELBO 表达式：

$$\begin{aligned}\mathcal{L}(q) &= \mathbb{E}_{q(Z)} [\log p(X|Z, \mu, \Lambda)] + \mathbb{E}_{q(Z)q(\pi)} [\log p(Z|\pi)] + \mathbb{E}_{q(\pi)} [\log p(\pi)] \\ &\quad + \mathbb{E}_{q(\mu, \Lambda)} [\log p(\mu, \Lambda)] - \mathbb{E}_{q(Z)} [\log q(Z)] - \mathbb{E}_{q(\pi)} [\log q(\pi)] - \mathbb{E}_{q(\mu, \Lambda)} [\log q(\mu, \Lambda)]\end{aligned}$$

这种方法可提升策略稳定性，并实现置信度感知的行为决策。

ELBO 已成为现代概率建模的统一语言与优化目标。无论是在生成建模 (VAE)、后验估计 (BNN)、文本聚类 (LDA)、还是策略学习 (RL) 中，*ELBO* 提供了一种稳定、理论完备的优化框架。随着模型复杂性的增加，对 *ELBO* 更高效、更精确的估计与优化方法也成为研究前沿。

6. *ELBO* 的改进与前沿方向

尽管 *ELBO* 在变分推断中发挥着核心作用，但其存在一些固有局限例如下界较松、优化过程易陷入局部最优等。因此，近年来针对 *ELBO* 的精度与适应性，提出了多种改进策略与扩展方法，以提升近似后验的质量和模型表达能力。

6.1. 更紧的下界 ^[35]

传统 *ELBO* 提供的是边缘似然 $\log p(x)$ 的一个下界，但该下界可能偏差较大。IWAE 提出使用多个样本进行重要性加权，得到更紧的下界：

$$\mathcal{L}_K = \mathbb{E}_{z_1, \dots, z_K \sim q(z|x)} \left[\log \left(\frac{1}{K} \sum_{k=1}^K \frac{p(x, z_k)}{q(z_k|x)} \right) \right]$$

当 $K = 1$ 时，该表达式退化为传统 *ELBO*；当 K 增大时， $\mathcal{L}_K$ 更接近 $\log p(x)$ ，从而提供更精确的优化目标。IWAE 改进了生成模型的训练稳定性与生成样本的多样性。

6.2. 替代 *KL* 散度的变分目标

ELBO 的推导依赖于 *KL* 散度尤其是 (尤其是 $KL(q(z)||p(z|x))$)，但 *KL* 散度具有“零覆盖问题”，即若 $q(z)$ 不覆盖 $p(z|x)$ 的支持区域，其值将趋于无穷，导致训练不稳定。为此，可以引入更一般的散度量。

6.2.1. χ 散度 ^[36]

χ 散度是 f -散度的一种形式，其定义为：

$$\chi^2(q||p) = \int \left(\frac{q(z)}{p(z)} - 1 \right)^2 p(z) dz$$

相比 *KL* 散度， χ 散度对 $p(z)$ 的尾部行为更加敏感，优化过程中鼓励更宽泛的支持区域。

6.2.2. *R-ELBO* ^[37]

基于 Rényi 散度的目标函数：

$$\mathcal{L}_\alpha = \frac{1}{1-\alpha} \log \mathbb{E}_{q(z)} \left[\left(\frac{p(x, z)}{q(z)} \right)^{1-\alpha} \right]$$

其中 α 是调节参数，当 $\alpha \rightarrow 1$ 时， $\mathcal{L}_\alpha$ 收敛为标准 *ELBO*。调节 α 可控制偏差与方差的权衡。

ELBO 虽为经典目标，但仍不断演化。未来，如何在表达能力、计算效率与收敛性之间平衡，将是 *ELBO* 研究的重要方向。

7. 总结

本文系统回顾了 *ELBO* (Evidence Lower Bound, 证据下界) 作为变分推断核心目标函数的理论基础与实际应用价值。从基本数学推导出发, 我们展示了 *ELBO* 如何通过 Jensen 不等式和 KL 散度的重写形式, 构建出一种可优化的、变分近似后验的评估指标。通过最大化 *ELBO*, 我们既可以近似最大化观测数据的对数边际似然, 又能最小化后验分布与近似分布之间的差异。

ELBO 在变分推断、生成模型、贝叶斯神经网络、聚类等众多任务中展现出广泛应用价值, 其优化技术也经历了从解析式更新、重参数化梯度、自然梯度到黑盒变分推断等多种演化形式。此外, 围绕其表达能力、优化稳定性与近似精度的不足, 研究者提出了诸如 IWAE、 χ -VI 等改进方向, 推动了高维复杂模型的可扩展推断。

参考文献

- [1] M. I. Jordan, Z. Ghahramani, T. Jaakkola, and L. K. Saul, An introduction to variational methods for graphical models, in *Machine Learning*, vol. 37, no. 2, pp. 183–233, 1999.
- [2] C. Zhang, J. Butepage, H. Kjellstrom, and S. Mandt, Advances in variational inference, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017.
- [3] T. N. Kipf and M. Welling, Variational Graph Auto-Encoders, *arXiv preprint arXiv:1611.07308*, 2016.
- [4] Y. Kim, S. Wiseman, and A. C. Miller, Semi-Amortized Variational Autoencoders, *Proc. Int. Conf. on Machine Learning (ICML)*, Stockholm, Sweden, 2018.
- [5] A. P. Dempster, N. M. Laird, and D. B. Rubin, Maximum likelihood from incomplete data via the EM algorithm, *Journal of the Royal Statistical Society, Series B*, vol. 39, no. 1, pp. 1–22, 1977.
- [6] Hun-Learning, EM Algorithm for Latent Variable Models –Derivation of the ELBO, *Hun-Learning Technical Blog*, 2019.
- [7] D. Daza, Expectation Maximization for Latent Variable Models –A Variational Perspective, *Daza’s Machine Learning Notes*, 2020.
- [8] D. M. Blei, A. Kucukelbir, and J. D. McAuliffe, Variational inference: A review for statisticians, *Journal of the American Statistical Association*, vol. 112, no. 518, pp. 859–877, 2017.
- [9] C. M. Bishop and N. M. Nasrabadi, Variational inference and the evidence lower bound, in *Pattern Recognition and Machine Learning*, Springer, 2006, ch. 10.
- [10] S. Odaibo, Tutorial: Deriving the Standard Variational Autoencoder (VAE) Loss

- Function, *arXiv preprint*, July 2019.
- [11] C. M. Bishop and N. M. Nasrabadi, Variational inference and the evidence lower bound, in *Pattern Recognition and Machine Learning*, Springer, 2006, ch. 10.
 - [12] D. M. Blei, A. Kucukelbir, and J. D. McAuliffe, Variational inference: A review for statisticians, *Journal of the American Statistical Association*, vol. 112, no. 518, pp. 859–877, 2017.
 - [13] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, Chapter 10.
 - [14] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework, *Proc. Int. Conf. on Learning Representations (ICLR)*, Toulon, France, 2017.
 - [15] C. P. Burgess, I. Higgins, A. Pal, L. Matthey, N. Watters, G. Desjardins, and A. Lerchner, Understanding disentangling in β -VAE, *arXiv preprint arXiv:1804.03599*, 2018.
 - [16] D. J. Rezende and S. Mohamed, Tighter variational bounds are not necessarily better, *Proc. Int. Conf. on Machine Learning (ICML)*, Stockholm, Sweden, 2018.
 - [17] D. Lyu, Z. Ghahramani, and F. Hernández-Lobato, Learning Interpretable Deep Disentangled Representations with Hyperbolic VAE, *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Virtual Conference, 2021.
 - [18] G. Parisi, *Statistical Field Theory*, Addison-Wesley, 1988, Chapter 5.
 - [19] M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul, An introduction to variational methods for graphical models, *Machine Learning*, vol. 37, no. 2, pp. 183–233, 1999.
 - [20] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006, Chapter 10.
 - [21] R. Ranganath, S. Gerrish, and D. M. Blei, Black Box Variational Inference, *Proc. 17th Int. Conf. on Artificial Intelligence and Statistics (AISTATS)*, Reykjavik, Iceland, 2014.
 - [22] M. D. Hoffman, D. M. Blei, C. Wang, and J. Paisley, Stochastic Variational Inference, *Journal of Machine Learning Research*, vol. 14, pp. 1303–1347, 2013.
 - [23] D. P. Kingma and M. Welling, Auto-Encoding Variational Bayes, *Proc. Int. Conf. on Learning Representations (ICLR)*, Banff, Canada, 2014.
 - [24] A. Mnih and D. J. Rezende, Variational Inference for Monte Carlo Objectives, *Proc. Int. Conf. on Machine Learning (ICML)*, Beijing, China, 2016.
 - [25] A. Kucukelbir, D. Tran, R. Ranganath, A. Gelman, and D. M. Blei, Automatic Differentiation Variational Inference, *Journal of Machine Learning Research*, vol. 18, no. 14, pp. 1–45, 2017.
 - [26] D. P. Kingma and M. Welling, Auto-Encoding Variational Bayes, in *Proc. 2nd Int.*

- Conf. on Learning Representations (ICLR)*, 2014.
- [27] D. P. Kingma and M. Welling, An introduction to variational autoencoders, *Foundations and Trends in Machine Learning*, vol. 12, no. 4, pp. 307–392, 2019.
 - [28] D. J. Rezende, S. Mohamed, and D. Wierstra, Stochastic Backpropagation and Approximate Inference in Deep Generative Models, *Proc. Int. Conf. on Machine Learning (ICML)*, Beijing, China, 2014.
 - [29] D. J. C. MacKay, A Practical Bayesian Framework for Backpropagation Networks, *Neural Computation*, vol. 4, no. 3, pp. 448–472, 1992.
 - [30] G. E. Hinton and D. van Camp, Keeping the Neural Networks Simple by Minimizing the Description Length of the Weights, *Proc. 6th Annu. Conf. on Computational Learning Theory (COLT)*, Santa Cruz, USA, 1993.
 - [31] D. M. Blei, A. Y. Ng, and M. I. Jordan, Latent Dirichlet Allocation, *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003.
 - [32] C. E. Rasmussen, The Infinite Gaussian Mixture Model, *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Denver, USA, 2000.
 - [33] J. Peters, K. Mülling, and Y. Altun, Relative Entropy Policy Search, *Proc. AAAI Conf. on Artificial Intelligence*, Atlanta, USA, 2010.
 - [34] G. Neumann and J. Peters, Fitted Q-iteration by Advantage Weighted Regression, *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Vancouver, Canada, 2009.
 - [35] Y. Burda, R. Grosse, and R. Salakhutdinov, Importance Weighted Autoencoders, *Proc. Int. Conf. on Machine Learning (ICML)*, New York, USA, 2016.
 - [36] K. Pearson, On the Criterion that a Given System of Deviations from the Probable in the Case of a Correlated System of Variables is Such that It Can Be Reasonably Supposed to Have Arisen from Random Sampling, *Philosophical Magazine*, vol. 50, no. 302, pp. 157–175, 1900.
 - [37] A. Rényi, On Measures of Entropy and Information, *Proc. 4th Berkeley Symp. on Mathematical Statistics and Probability*, vol. 1, pp. 547–561, 1961.